

**Prediksi harga saham menggunakan *technical indicators*
dengan *convolutional neural network (CNN)***

***Stock price prediction using technical indicators
with convolutional neural network (CNN)***

Titan Muslim Al-Khan¹, Titis Fikri Aji Kusuma¹

¹Prodi Oseanografi, Fakultas Ilmu Teknologi dan Kebumihan, Institut Teknologi Bandung
Jl. Ganeca no 10, Kota Bandung Jawa Barat.

Email:

alkhantitan@gmail.com

titisfikri123@gmail.com

Abstrak

Prediksi indeks harga saham memiliki peranan penting dalam strategi dagang suatu perusahaan. Namun dalam pengimplementasiannya sulit untuk dilakukan, dikarenakan banyak faktor yang terlibat didalamnya. Untuk menyelesaikan permasalahan tersebut, digunakan pendekatan model *deep learning*, yaitu *convolutional neural network (CNN)*. Model CNN tersebut diaplikasikan untuk memprediksi indeks harga saham Microsoft. Dalam model tersebut, digunakan 15 indikator teknis yang berkaitan dengan indeks harga saham dan 10 nilai diwaktu sebelumnya yang digunakan sebagai input. Sebelum dimasukan kedalam model, data input tersebut disusun menjadi gambar 2D. Dengan menggunakan *metrics* evaluasi RMSE, diperoleh bahwa model kami mampu memprediksi pola dengan baik pada saat fase *training* dan *testing*. Namun hasil yang diperoleh masih memberikan nilai yang cenderung *underestimate* pada data dengan tren menaik yang signifikan.

Kata Kunci : Harga saham, indikator teknis, *model*, *deep learning*, *convolutional neural network*.

Abstract

Stock price index prediction has an important role in a company's trading strategy. However, the implementation is difficult to do, because there are many factors involved in it. To solve these problems, a deep learning model approach is used, namely the convolutional neural network (CNN). The CNN model was applied to predict Microsoft's stock price index. In this model, 15 technical indicators related to the stock price index and 10 previous values were used as input. Before entering into the model, the input data is arranged into 2D images. By using the RMSE evaluation metrics, it was found that our model was able to predict patterns well during the training and testing phase. But the results obtained still provide values that tend to underestimate data with a significant upward trend.

Keywords: *Stock price, technical indicators, model, deep learning, convolutional neural network.*

1. PENDAHULUAN

Saham adalah sebuah bukti kepemilikan nilai suatu perusahaan [1]. Dengan menerbitkan saham, memungkinkan perusahaan-perusahaan yang membutuhkan pendanaan jangka panjang untuk 'menjual' kepentingan dalam bisnis - saham (efek ekuitas) - dengan imbalan uang tunai [2]. Sehingga, prediksi harga saham memeran peranan penting dalam strategi dagang perusahaan, karena dapat digunakan untuk mengidentifikasi kesempatan untuk membeli dan menjual saham [8].

Prediksi harga saham, merupakan salah satu hal yang sulit untuk dilakukan oleh para peneliti dan spekulator [8]. Hal tersebut dikarenakan ada banyak faktor yang memengaruhinya, sehingga perilakunya sangat dinamis. Faktor-faktor yang berpengaruh tersebut seperti pengembalian aset,

pengembalian saham, turunnya kepercayaan masyarakat, kondisi ekonomi negara, peraturan pemerintahan, laju inflasi serta masih banyak faktor lainnya [3].

Oleh karena itu, investor seringkali mengalami kesulitan dalam menentukan kapan akan menambah atau menahan jumlah investasinya akibat fluktuasi harga saham, sehingga diperlukan sebuah sistem yang dapat memprediksi fluktuasi harga saham agar memudahkan para investor dalam berinvestasi pada saham perusahaan tertentu.

Prediksi harga saham dapat dilakukan dengan model statistik, seperti regresi linear dan *auto regression moving average* (ARMA) [8]. Namun, metode konvensional tersebut memiliki performa yang kurang baik dalam memprediksi saham, dikarenakan faktor non-linear dari setiap variabelnya [9].

Dalam beberapa tahun ini, bidang *deep learning* telah mengalami perkembangan yang pesat, dikarenakan kemampuannya dalam menyelesaikan permasalahan yang kompleks. Penggunaan *deep learning* telah diterapkan di banyak bidang, seperti bidang kesehatan dan keuangan. Hasil yang diperoleh darinya telah terbukti mengungguli metode konvensional dalam menyelesaikan masalah prediksi/klasifikasi [4].

Aplikasi dari *deep learning* yang sudah digunakan dalam bidang keuangan, seperti model *recurrent neural network* (RNN) [5] dan *long short-term memory* (LSTM) [6]. Selain RNN dan LSTM, model *convolutional neural networks* (CNN) dapat digunakan dalam bidang keuangan, seperti yang telah dilakukan oleh Sezer dkk. [7], yang menggunakan CNN dalam menentukan *trading strategies*.

Sejak tahun 2000, model CNN telah sukses dalam menyelesaikan masalah dalam deteksi, segmentasi, dan pengenalan objek [10]. Selain dalam bidang *computer vision*, CNN telah diaplikasikan dalam bidang pengolahan bahasa alami [12]. Permasalahan tersebut melibatkan banyak fitur, sehingga diperlukan model yang mampu menangkap fitur penting di antara banyak fitur lainnya, yang dalam hal ini CNN mampu dengan baik melakukan hal tersebut [10].

Sama halnya yang telah dilakukan oleh Sezer dkk. [7], dalam penelitian ini digunakan model CNN untuk memprediksi indeks harga saham. Saat digunakan untuk memprediksi fluktuasi indeks harga saham, CNN menggunakan parameter terkait seperti indikator

teknis, yang dalam hal ini dapat menghasilkan prediksi yang lebih baik dibandingkan model konvensional, RNN, dan LSTM, seperti yang telah dilakukan oleh Sezer dkk. [7].

2. METODOLOGI


2.1 Persiapan data

Dalam studi ini, digunakan data historis selama 20 tahun, dari Juni 2000 sampai April 2020. Data historis tersebut merupakan harga saham microsoft (MSFT) yang terdiri dari 15 indikator teknis yang mewakilinya. Semua data tersebut diperoleh dari situs <https://www.alphavantage.co/>.

Data sepanjang 20 tahun tersebut dibagi menjadi tiga, yaitu data *training*, *validation*, dan *testing*. Ketiga data tersebut dibagi dengan persentase 70% (*training*), 20% (*validation*), dan 10% (*testing*).

2.1 Pembuatan input fitur

Dalam penelitian-penelitian sebelumnya, tidak ada kriteria khusus dalam pembuatan fitur untuk memprediksi pergerakan indeks harga saham [9]. Dari setiap indikator teknis, digunakan 10 data di waktu sebelumnya sebagai input model. Sezer dkk. [7], menyusun setiap indikator teknis menjadi gambar 2D, dengan fitur yang memiliki hubungan keterkaitan ditempatkan secara berdekatan. Korelasi dari setiap indikator teknis tersebut ditunjukkan oleh matriks *heatmap* korelasi, yang ditunjukkan oleh Gambar 1.



Gambar 1. Matriks *heatmap* korelasi


Nilai dari setiap input fitur tersebut distandarisasi dengan menggunakan persamaan (1). Hal tersebut dilakukan untuk memudahkan model *deep learning* dalam mempelajari pola didalamnya.

$$X_{ts} = \frac{X_t - X_{max}}{X_{min} - X_{max}} \quad (1)$$

dengan X_{ts} merupakan nilai fitur pada observasi ke- t yang sudah distandarisasi; X_t nilai fitur pada observasi ke- t ; X_{max} nilai observasi fitur maksimum; X_{min} nilai observasi fitur minimum.

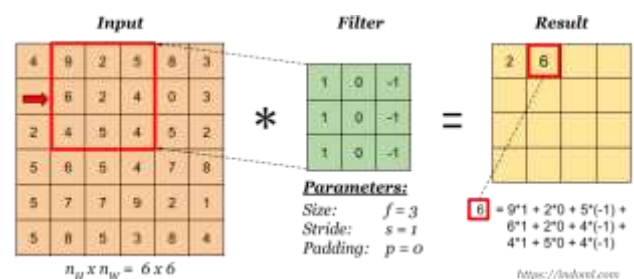
2.2 Convolutional neural network

CNN didesain untuk memproses data yang tersusun oleh banyak *array*, seperti gambar yang direpresentasikan sebagai *array* 2D yang tersusun atas intensitas pixel [10]. Arsitektur CNN secara umum terbagi menjadi *input layer*, *convolution layer*, *max pooling (subsampling) layer*, dan *fully connected layer*. Ilustrasi model CNN dalam memproses gambar ditunjukkan oleh Gambar 2.



Gambar 2. Ilustrasi pemrosesan gambar dalam model CNN (Sumber: LeCun, dkk., 2015)

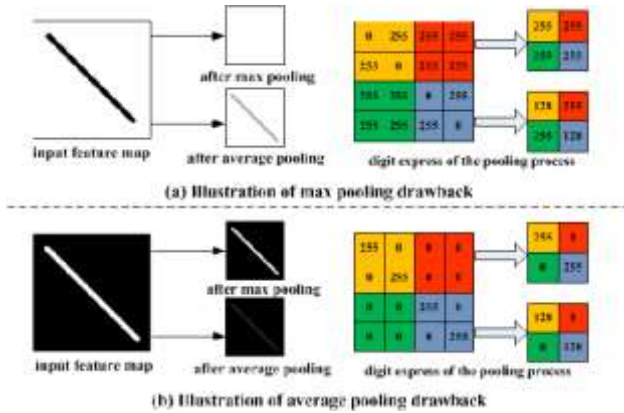
Setiap fitur dari *input layer* akan diekstraks fitur pentingnya melalui proses konvolusi. Fitur-fitur penting tersebut dipetakan oleh kernel konvolusi yang dinamakan filter [11]. Pemetaan fitur diperoleh dari hasil penjumlahan dari proses *element wise* antara data input dengan filter yang telah ditentukan. Kemudian filter tersebut akan menyusuri seluruh fitur yang ada pada data input, sebagaimana seperti yang ditunjukkan oleh Gambar 3.



Gambar 3. Ilustrasi proses *convolutional layer* (Sumber : Indoml.com)

Selanjutnya, hasil dari konvolusi (*feature maps*) akan dijalarkan ke *subsampling layer*. Pada layer tersebut *feature maps* akan direduksi dimensinya. Terdapat dua metode dalam *subsampling*, yaitu *max pooling* dan *average pooling*. Pada *max pooling*, akan diambil nilai tertinggi dari *feature maps*. Sedangkan pada *average pooling*, akan diambil nilai rata-rata dari

feature maps. Ilustrasi proses pengolahan *feature maps* dari kedua metode *subsampling* tersebut ditunjukkan oleh Gambar 4.



Gambar 4. Perbandingan *max pooling* dan *average pooling* (Sumber: Quora.com)

Layer terakhir pada model CNN adalah *fully connected layer*. Pada layer tersebut akan dilakukan transformasi dimensi data, sehingga dapat dilakukan klasifikasi secara linear, yang dalam hal ini dapat digunakan sebagai input bagi *artificial neural network* (ANN). Pada ANN terdapat dua proses, yaitu *forward propagation* dan *backward propagation*.

2.3 Metode evaluasi

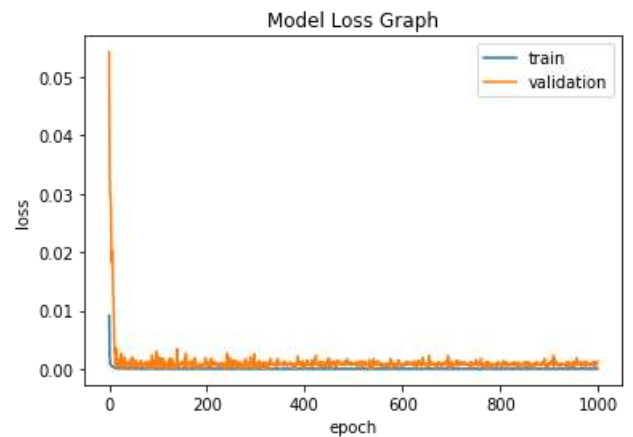
Dalam mengukur performa model, digunakan *root mean squared error* (RMSE). RMSE digunakan untuk mengevaluasi *error* rata-rata secara keseluruhan antara hasil prediksi terhadap nilai sebenarnya. RMSE dapat dinyatakan oleh persamaan, seperti yang ditunjukkan oleh persamaan (2).

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_{i,pred} - y_{i,act})^2}{n}} \quad (2)$$

dengan $y_{i,pred}$ hasil prediksi model ke- i ; y_{act} nilai yang sebenarnya ke- i ; n jumlah observasi.

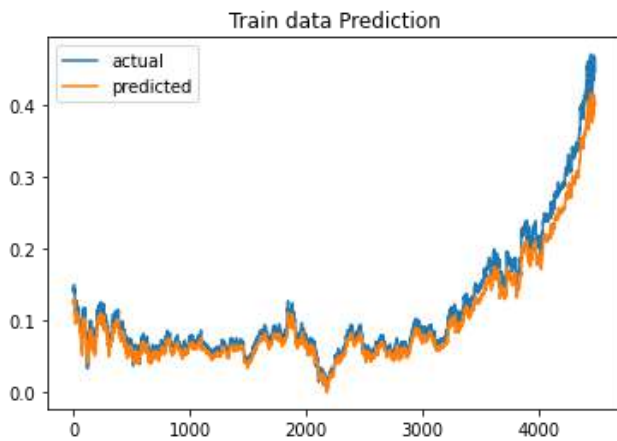
3 Hasil eksperimen

Dari hasil eksperimen yang telah dilakukan, diperoleh hasil prediksi model pada fase *training* dan *testing* seperti yang ditunjukkan oleh Gambar 6 dan 7.




Gambar 5. Grafik *loss* model antara *train* data dan *validation* data

Seperti yang ditunjukkan oleh Gambar 6, terjadi penurunan nilai *error* saat memprediksi data *training* dan *test*. Hal tersebut menunjukkan adanya proses belajar pada model. Selain itu, terdapat perbedaan karakteristik grafik yang signifikan antara grafik *loss* data *training* dan *test*. Pada data *training*, grafik *loss* terlihat lebih *smooth*, dibandingkan pada data *validation* yang cenderung lebih fluktuatif. Hal tersebut dikarenakan data *validation* lebih variatif dibandingkan data *training*, seperti yang ditunjukkan oleh Gambar 6 dan 7.



Gambar 6. Grafik perbandingan data aktual dan data prediksi model dari *train* data



Gambar 7. Grafik perbandingan data test dengan prediksi model

Berdasarkan Gambar 6 dan 7, dapat diketahui pada saat *training* model memberikan performa yang sangat baik, kecuali pada data dengan tren menaik. Berbeda dengan data *training*, saat memprediksi data *test*, secara keseluruhan, model dapat dengan baik dalam mempelajari pola pada data tersebut, namun nilai yang diperoleh cenderung *underestimate*. Berdasarkan nilai RMSE, diperoleh untuk data *training* RMSE bernilai 0,019, sedangkan untuk data *test* bernilai 0,085. Dari nilai RMSE tersebut, dapat diketahui performa model menurun ketika diuji dengan data *test*. Seperti

yang telah dijelaskan sebelumnya, hal tersebut dikarenakan adanya perbedaan karakteristik data antara data *training* yang cenderung stasioner diawal, dan memiliki tren menaik diakhir. Sedangkan data *test* secara keseluruhan memiliki tren yang menaik, yang dalam hal ini, model masih kesulitan dalam memprediksi data dengan tren tersebut.

4 Diskusi

Untuk mendapatkan hasil yang baik dalam memprediksi data indeks harga saham MSFT (Microsoft Corp.) kami melakukan pemilihan jenis jenis *technical indicators* melalui uji sensitivitas model dan *exploratory data analysis* (EDA). Uji sensitivitas model adalah metode memilih fitur yang digunakan pada sebuah model *neural network* dengan melihat kontribusi fitur tersebut terhadap prediksi yang dihasilkan model sedangkan *exploratory data analysis* adalah proses menganalisis data dan membandingkan nilai statistik antar fitur seperti korelasi, variansi dan rata-rata. Dari kedua proses diatas, didapatkanlah 15 fitur *technical indicators* yang digunakan pada model ini.

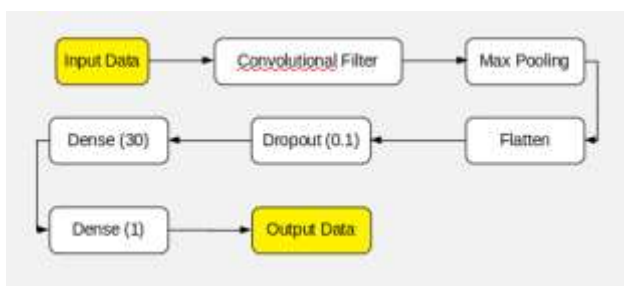
Kemudian, dilakukan *tuning hyperparameter* model untuk mendapatkan hasil prediksi yang baik. Adapun yang kami ubah adalah banyaknya filter konvolusi, ukuran kernel, *padding*, dan banyaknya *hidden layer* pada model. Selain itu kami juga menambahkan *dropout layer* pada model, bertujuan untuk mengurangi tingkat *overfitting* pada hasil. Sehingga didapatkan model yang paling baik

yang kami dapatkan yaitu dengan konfigurasi dibawah ini :

Tabel 1. Nilai Hyperparameter Model

<i>Hyperparameter</i>	Nilai
<i>Time step</i>	10
<i>Conv. Filter</i>	5
<i>Kernel Size Conv. filter</i>	1,3
<i>padding</i>	“same”
<i>Max pooling size</i>	1,2
<i>Dropout</i>	0.1
<i>Hidden Layer</i>	30

Adapun konfigurasi model dapat dijelaskan dalam diagram dibawah ini :



Gambar 8. Konfigurasi Model

Kemudian, walaupun penulis mengatakan bahwa model yang digunakan sudah model yang paling baik, namun nyatanya kami tetap menemui *overfitting* pada model. Hal ini ditandai pada hasil *training* yang bagus namun model tidak bisa mengenali data *test* dengan baik.

Dapat dilihat juga terdapat kesalahan yang sistematis dari prediksi data test, dimana model prediksi seakan bergeser dari data aktual. hal ini disebabkan oleh banyak faktor, salah satunya adalah adanya kemungkinan model “menghafal” data bukan mempelajari nya, sehingga hasil prediksi nya terlambat beberapa *time step* menghasilkan gambar 7.

Selain itu, model yang dibangun tidaklah *reproducible*. Karena seringkali diperoleh hasil berbeda yang cukup signifikan ketika dijalankan ulang. Hal ini disebabkan oleh *randomness* yang dihasilkan oleh *initial weight*, *regularization* seperti Dropout, dan di *Optimizer* yang digunakan.

5 Kontribusi

Kedua peneliti yang menyusun tulisan ini memberikan kontribusi yang sama dalam pembuatan model dan penyusunan *paper* ini.

Tiap bab dari tulisan ini dari abstrak, pendahuluan, metodologi dan diskusi tugas nya dibagi-bagi secara merata dan saling mengoreksi apabila terdapat kesalahan atau kekurangan.

REFERENSI

- [1] Darmadji, Tjiptono, and Hendy M. Fakhruddin. "Pasar modal di indonesia." Jakarta: Salemba Empat (2001).
- [2] Dalton, John M., and John Dalton. How the stock market works. New York Institute of Finance, 1988.
- [3] S. S. Kewal, “Pengaruh Inflasi, Suku Bunga, Kurs, dan Pertumbuhan PDB

- Terhadap Indeks Harga Saham Gabungan,” *Jurnal Economia.*, Vol. 8, No. 1, Pp. 53–64, 2012.
- [4] A. Canziani, A. Paszke, E. Culurciello, An Analysis of Deep Neural Network Models for Practical Applications, 2016 arXiv:1605.07678
- [5] C. Krauss, X.A. Do, N. Huck, Deep neural networks, gradient-boosted trees, random forests: statistical arbitrage on the s&p 500, *Eur. J. Oper. Res.* 259 (2) (2017) 689–702.
- [6] T. Fischer, C. Krauß, Deep Learning with Long Short-term Memory Networks for Financial Market Predictions, Tech. Rep., FAU Discussion Papers in Economics, 2017.
- [7] Sezer, Omer Berat, and Ahmet Murat Ozbayoglu. "Algorithmic financial trading with deep convolutional neural networks: Time series to image conversion approach." *Applied Soft Computing* 70 (2018): 525-538.
- [8] Long, W., Lu, Z. and Cui, L., 2019. Deep learning-based feature engineering for stock price movement prediction. *Knowledge-Based Systems*, 164, pp.163-173.
- [9] Jiang, M., Liu, J., Zhang, L. and Liu, C., 2020. An improved Stacking framework for stock index prediction by leveraging tree-based ensemble models and deep learning algorithms. *Physica A: Statistical Mechanics and its Applications*, 541, p.122272.
- [10] LeCun, Y., Bengio, Y. and Hinton, G., 2015. Deep learning. *nature*, 521(7553), pp.436-444.
- [11] Putra, I.W.S.E., 2016. Klasifikasi Citra Menggunakan Convolutional Neural Network (CNN) pada Caltech 101 (Doctoral dissertation, Institut Teknologi Sepuluh Nopember).
- [12] Bhandare, A., Bhide, M., Gokhale, P. and Chandavarkar, R., 2016. Applications of convolutional neural networks. *International Journal of Computer Science and Information Technologies*, 7(5), pp.2206-2215.

